

Лабораторна робота №1

Тензори, матричні операції та порівняння CPU/GPU

Виконав: Роман Миджин · GitHub: Roman2945 · 25 вересня 2026 р.

Мета роботи

Реалізувати базові операції над векторами й матрицями без сторонніх бібліотек; побудувати лінійний шар $y = Wx + b$; порівняти час матричного множення в PyTorch на CPU та NVIDIA GPU.

Реалізація

Функція	Призначення	Складність часу
<code>vector_add(a, b)</code>	Поелементна сума двох векторів	$O(n)$
<code>dot(a, b)</code>	Скалярний добуток	$O(n)$
<code>matvec(A, x)</code>	Добуток матриці $m \times n$ на вектор	$O(mn)$
<code>shape(t)</code>	Форма вкладеного тензора	$O(N)$
<code>linear(x, W, b)</code>	Один лінійний шар	$O(mn)$
<code>matmul(A, B)</code>	Добуток $m \times n$ і $n \times p$	$O(mnp)$
<code>transpose(A)</code>	Транспонування матриці	$O(mn)$
<code>linear_batch(X, W, b)</code>	Лінійний шар для батчу	$O(Bmn)$

У формулах N - кількість скалярів у тензорі, B - розмір батчу.

Ключові співвідношення

$\text{dot}(a, b) = \sum_i a_i b_i$; $(Ax)_i = \sum_j A_{ij} x_j$; $(AB)_{ij} = \sum_k A_{ik} B_{kj}$; $y = Wx + b$.

Функції перевіряють сумісність розмірів та відхиляють нерівні рядки матриць. Для порожніх векторів скалярний добуток дорівнює 0; порожня матриця без визначеної ширини викликає `ValueError`.

Перевірка правильності

Усі 8 наборів тестів з вихідного завдання пройдено. Зокрема $\text{dot}([1,2,3],[4,5,6]) = 32$, $\text{matmul}([1,2,3],[4,5,6],[1,2],[3,4],[5,6]) = [[22,28],[49,64]]$ і $\text{linear}([2,3], W, b) = [12,23,35]$ для наведених у завданні W та b .

Експеримент CPU та GPU

Обладнання та методика

CPU: AMD Ryzen 5 4600H. GPU: NVIDIA GeForce RTX 2060. Python 3.12.7; PyTorch 2.11.0+cu128; CUDA 12.8. Матриці квадратні, float32, значення з фіксованим seed=42. Перед вимірюванням - 10 прогрівальних викликів. Для кожного розміру виконано 5 серій; у таблиці - медіана часу одного добутку. Тензори перенесено на GPU до початку вимірювання, після серії викликів GPU синхронізовано.

Результати

Розмір	CPU, мс	GPU, мс	CPU/GPU
16 × 16	0.0049	0.0414	0.12×
128 × 128	0.0322	0.0312	1.03×
1024 × 1024	9.4046	0.6817	13.80×
2048 × 2048	63.5741	2.9659	21.44×

Коефіцієнт CPU/GPU більший за 1 означає перевагу GPU. Перевірка PyTorch підтвердила збіг результатів CPU та GPU з допуском для float32 (rtol=0.001, atol=0.001).

Аналіз

Для матриць 16 × 16 співвідношення CPU/GPU становить 0.12×: запуск операції на GPU має помітні накладні витрати. Для 2048 × 2048 воно становить 21.44×. Зі збільшенням задачі паралельні обчислення GPU ефективніше перекривають ці витрати. Вимірювання не включає копіювання тензорів між RAM і VRAM, тому це швидкість самого множення, а не повний час сценарію з передачами даних.

Висновок

Навчальна реалізація показує, як добуток матриць складається зі скалярних добутків. Лінійний шар застосовує матрично-векторне множення і додає bias; для батчу це еквівалентно $XW^T + b$. На великих матрицях PyTorch використовує оптимізовані ядра, а GPU виграє завдяки паралельному виконанню. Числа залежать від апаратного забезпечення та навантаження системи.

Відтворення

У корені проєкту: `python matmul.py` для тестів; `python benchmark.py` для таблиці CPU/GPU. Вихідне завдання: <https://github.com/lpnu-llm/lab-tensors>